



Programmierung und Deskriptive Statistik

BSc Psychologie WiSe 2025/26

Belinda Fleischmann und Dirk Ostwald

	Gruppe 1/2	Gruppe 3	Format	Thema
1	Mi, 15.10.	Do, 16.10.	Seminar	(1) Grundbegriffe der Informatik
2	Mi, 22.10.	Do, 23.10.	Seminar	(2) Arithmetik und Variablen
3	Mi, 29.10.	Do, 30.10.	Übung	(2) Arithmetik und Variablen
4	Mi, 05.11.	Do, 06.11.	Seminar	(3) Vektoren und Matrizen
5	Mi, 12.11.	Do, 13.11.	Übung	(3) Vektoren und Matrizen
6	Mi, 19.11.	Do, 20.11.	Seminar	(4) Listen und Dataframes
7	Mi, 26.11.	Do, 27.11.	Übung	(4) Listen und Dataframes
8	Mi, 03.12.	Do, 04.12.	Seminar	(5) Datenmanagement
9	Mi, 10.12.	Do, 11.12.	Übung	(5) Datenmanagement
	Mo, 15.12		Abgabe	<i>Individuelleistung (1/2)</i>
10	Mi, 17.12.	Do, 18.12.	Seminar	(6) Strukturiertes Progr.: Kontrollfluss, Debugging
11	Mi, 07.01.	Do, 08.01.	Seminar	(7) Häufigkeitsverteilungen
12	Mi, 14.01.	Do, 15.01.	Übung	(7) Häufigkeitsverteilungen
13	Mi, 21.01.	Do, 22.01.	Seminar	(8) Maße der zentralen Tendenz und Datenvariabilität
14	Mi, 28.01.	Do, 29.01.	Übung	(8) Maße der zentralen Tendenz und Datenvariabilität
	Mo, 02.02		Abgabe	<i>Individuelleistung (2/2)</i>

(9) Maße der zentralen Tendenz und
Datenvariabilität

Maße der zentralen Tendenz

Maße der Datenvariabilität

Maße der zentralen Tendenz

Maße der Datenvariabilität

Definition (Mittelwert)

$y = (y_1, \dots, y_n)$ sei ein Datensatz. Dann heißt

$$\bar{y} := \frac{1}{n} \sum_{i=1}^n y_i \quad (1)$$

der *Mittelwert* von y .

Bemerkung

- Der hier definierte Mittelwert wird auch als *arithmetisches Mittel* oder *Durchschnitt* bezeichnet.
- Im Kontext der Inferenzstatistik heißt der Mittelwert *Stichprobenmittel*.
- Die Inferenzstatistik gibt der Mittelwertsbildung ihren Sinn.

Berechnung des Mittelwerts in R

Berechnung des Mittelwerts anhand der in (1) festgelegten Formel

```
# Einlesen des Beispieldatensatzes
dateipfad    <- file.path(datenordner, "psychotherapie_datensatz.csv")
D            <- read.csv(dateipfad)

# Mittelwertberechnung
y            <- D$Pre.BDI                # Pre-Interventions-BDI-II-Daten
n            <- length(y)                # Anzahl der Werte
y_bar        <- (1 / n) * sum(y)         # Mittelwertberechnung

cat("Mittelwert der PRE-BDI-II-Daten ", mean(y)) # Ausgabe
```

Mittelwert der PRE-BDI-II-Daten 18.61

Berechnung des Mittelwerts mit mean()

```
y_bar <- mean(y)                # Mittelwertberechnung

cat("Mittelwert der PRE-BDI-II-Daten ", mean(y)) # Ausgabe
```

Mittelwert der PRE-BDI-II-Daten 18.61

Theorem (Zentralitätseigenschaften des Mittelwerts)

$y = (y_1, \dots, y_n)$ sei ein Datensatz und $\bar{y}$ sei der Mittelwert von y . Dann gelten

(1) Die Summe der Abweichungen vom Mittelwert ist Null,

$$\sum_{i=1}^n (y_i - \bar{y}) = 0. \quad (2)$$

(2) Die absoluten Summen negativer und positiver Abweichungen vom Mittelwert sind gleich, d.h. wenn $j = 1, \dots, n_j$ die Datenpunktindizes mit $(y_j - \bar{y}) < 0$ und $k = 1, \dots, n_k$ die Datenpunktindizes mit $(y_k - \bar{y}) \geq 0$ bezeichnen, dann gilt mit $n_j + n_k$, dass

$$\left| \sum_{j=1}^{n_j} (y_j - \bar{y}) \right| = \left| \sum_{k=1}^{n_k} (y_k - \bar{y}) \right|. \quad (3)$$

Zentralitätseigenschaften des Mittelwerts

Beweis

(1) Es gilt

$$\begin{aligned}\sum_{i=1}^n (y_i - \bar{y}) &= \sum_{i=1}^n y_i - \sum_{i=1}^n \bar{y} \\ &= \sum_{i=1}^n y_i - n\bar{y} \\ &= \sum_{i=1}^n y_i - \frac{n}{n} \sum_{i=1}^n y_i \\ &= \sum_{i=1}^n y_i - \sum_{i=1}^n y_i \\ &= 0.\end{aligned}\tag{4}$$

Verifizierung in R

```
y <- D$Pre.BDI # Pre-Interventions-BDI-II-Daten
s <- sum(y - mean(y)) # Summe der Abweichungen vom Mittelwert

cat("Summe der Abweichungen vom Mittelwert:", round(s,2)) # Ausgabe
```

Summe der Abweichungen vom Mittelwert: 0

Zentralitätseigenschaften des Mittelwerts

Beweis

(2) Seien $j = 1, \dots, n_j$ die Indizes mit $(y_j - \bar{y}) < 0$ und $k = 1, \dots, n_k$ die Indizes mit $(y_k - \bar{y}) \geq 0$, so dass $n = n_j + n_k$. Dann gilt

$$\begin{aligned} \sum_{i=1}^n (y_i - \bar{y}) &= 0 \\ \Leftrightarrow \sum_{j=1}^{n_j} (y_j - \bar{y}) + \sum_{k=1}^{n_k} (y_k - \bar{y}) &= 0 \\ \Leftrightarrow \sum_{k=1}^{n_k} (y_k - \bar{y}) &= - \sum_{j=1}^{n_j} (y_j - \bar{y}) \\ \Leftrightarrow \left| \sum_{j=1}^{n_j} (y_j - \bar{y}) \right| &= \left| \sum_{k=1}^{n_k} (y_k - \bar{y}) \right|. \end{aligned} \tag{5}$$

Verifizierung in R

```
s_1 <- sum(y[y <= mean(y)] - mean(y))      # Summe aller negativer Abweichungen
s_2 <- sum(y[y > mean(y)] - mean(y))        # Summe aller positiver Abweichungen

cat("Summen der positiven und negativen Abweichungen:", # Ausgabe
    round(s_1,2), round(s_2,2))
```

Summen der positiven und negativen Abweichungen: -71.28 71.28

Theorem (Summationsseigenschaften des Mittelwerts)

Gegeben seien zwei Datensätze $y = (y_1, \dots, y_n)$ und $z = (z_1, \dots, z_n)$ gleichen Umfangs und es sei durch

$$y + z := (y_1 + z_1, \dots, y_n + z_n) \quad (6)$$

die Summe dieser Datensätze definiert. Weiterhin seien $\bar{y}$ und $\bar{z}$ die Mittelwerte der Datensätze y und z , respektive. Dann gilt

$$\overline{y + z} = \bar{y} + \bar{z} \quad (7)$$

Summationsseigenschaften des Mittelwerts

Beweis

Es gilt

$$\begin{aligned}\overline{y+z} &:= \frac{1}{n} \sum_{i=1}^n (y_i + z_i) \\ &= \frac{1}{n} \sum_{i=1}^n y_i + \frac{1}{n} \sum_{i=1}^n z_i \\ &=: \bar{y} + \bar{z}.\end{aligned}\tag{8}$$

Verifizierung in R

```
y      <- D$Pre.BDI           # Pre-Interventions-BDI-II-Daten
y_bar  <- mean(y)             # Mittelwert der Pre.BDI-Werte
z      <- D$Post.BDI          # double Vektor der Post.BDI Werte
z_bar  <- mean(z)             # Mittelwert der Post.BDI Werte
yz_bar_1 <- mean(y + z)       # Mittelwert der summierten Daten
yz_bar_2 <- y_bar + z_bar     # Summe der Mittelwerte der Daten

cat("Mittelwert von z           :", yz_bar_1, # Ausgabe
    "\nSumme der Mittelwerte von y und z:", yz_bar_2)
```

Mittelwert von z : 31.68

Summe der Mittelwerte von y und z: 31.68

Theorem (Linear-affine Transformation)

$y = (y_1, \dots, y_n)$ sei ein Datensatz und $\bar{y}$ sei der Mittelwert von y . Weiterhin sei für $a, b \in \mathbb{R}$ mit

$$ay + b := (ay_1 + b, \dots, ay_n + b) \quad (9)$$

ein linear-affin transformierter Datensatz von y definiert. Dann gilt, dass

$$\overline{ay + b} = a\bar{y} + b \quad (10)$$

Beweis Es gilt

$$\begin{aligned}\overline{ay + b} &:= \frac{1}{n} \sum_{i=1}^n (ay_i + b) \\ &= \sum_{i=1}^n \left(\frac{1}{n} ay_i + \frac{1}{n} b \right) \\ &= \left(\sum_{i=1}^n \frac{1}{n} ay_i \right) + \left(\sum_{i=1}^n \frac{1}{n} b \right) \\ &= a \left(\frac{1}{n} \sum_{i=1}^n y_i \right) + \frac{1}{n} \sum_{i=1}^n b \\ &= a\bar{y} + \frac{1}{n} nb \\ &= a\bar{y} + b.\end{aligned}\tag{11}$$

Linear-affine Transformation

Verifizierung in R

```
y      <- D$Pre.BDI           # Pre-Interventions-BDI-II-Daten
y_bar  <- mean(y)             # Mittelwert der Pre.BDI-Werte
a      <- 2                   # Multiplikationskonstante
b      <- 5                   # Additionskonstante
z      <- a*y + b             # linear-affine Transformation der Pre.BDI-Werte
z_bar  <- mean(z)             # Mittelwert der transformierten Pre.BDI-Werte
ay_bar_b <- a*y_bar + b      # Transformation des Pre.BDI-Mittelwerts

cat("Mittelwert des transformierten Datensatzes:", z_bar,      # Ausgabe
    "\nTransformation des Mittelwertes      :", ay_bar_b)
```

```
Mittelwert des transformierten Datensatzes: 42.22
Transformation des Mittelwertes      : 42.22
```

Definition (Median)

$y = (y_1, \dots, y_n)$ sei ein Datensatz und $y_s = (y_{(1)}, \dots, y_{(n)})$ der zugehörige aufsteigend sortierte Datensatz. Dann ist der Median von y definiert als

$$\tilde{y} := \begin{cases} y_{((n+1)/2)} & \text{falls } n \text{ ungerade,} \\ \frac{1}{2} (y_{(n/2)} + y_{(n/2+1)}) & \text{falls } n \text{ gerade.} \end{cases} \quad (12)$$

Bemerkungen

- Der Median ist identisch mit dem 0.5-Quantil.
- Mindestens 50% aller y_i sind kleiner oder gleich $\tilde{y}$
- Mindestens 50% aller y_i sind größer oder gleich $\tilde{y}$.
- Anstelle eines Beweises verweisen wir auf untenstehende Abbildungen.


Median - Beispiele

Beispiele

A

Beispiel für n ungerade

$$n := 5 \Rightarrow \left(\frac{5+1}{2}\right) = (3) \Rightarrow \hat{y} := y_{(3)}$$




$$y_{(1)}, y_{(2)}, y_{(3)} \leq \hat{y} \leq y_{(3)}, y_{(4)}, y_{(5)}$$

B

Beispiel für n gerade

$$n := 6 \Rightarrow \left(\frac{6}{2}\right) = (3), \left(\frac{6}{2} + 1\right) = (4) \Rightarrow \hat{y} := \frac{1}{2}(y_{(3)} + y_{(4)})$$



$$y_{(1)}, y_{(2)}, y_{(3)} < \hat{y} < y_{(4)}, y_{(5)}, y_{(6)}$$

Berechnung des Medians in R

Bestimmung des Medians anhand der in (12) festgelegten Formeln

```
y <- D$Pre.BDI # Pre-Interventions-BDI-II-Daten
n <- length(y) # Anzahl der Werte
y_s <- sort(y) # aufsteigend sortierter Vektor
if (n %% 2 == 1) { # n ungerade, n mod 2 == 1
  y_tilde <- y_s[(n + 1) / 2]
} else { # n gerade, n mod 2 == 0
  y_tilde <- (y_s[n / 2] + y_s[n / 2 + 1]) / 2
}

cat("Median der PRE-BDI-II-Daten:", median(y)) # Ausgabe
```

Median der PRE-BDI-II-Daten: 19

Berechnung des Medians mit median()

```
y_tilde <- median(y) # Berechnung des Medians

cat("Median der PRE-BDI-II-Daten:", median(y_tilde)) # Ausgabe
```

Median der PRE-BDI-II-Daten: 19

Der Median ist weniger anfällig für Ausreißer als der Mittelwert

```
y      <- D$Pre.BDI           # Pre-Interventions-BDI-II-Daten
y_bar  <- mean(y)             # Mittelwert
y_tilde <- median(y)          # Median

cat("Mittelwert und Median für Datensatz ohne Ausreißer:", # Ausgabe
    mean(y), median(y))
```

Mittelwert und Median für Datensatz ohne Ausreißer: 18.61 19

```
z      <- y                   # neuer Datensatz...
z[1]   <- 10000               # ... mit einem Extremwert
z_bar  <- mean(z)             # Mittelwert des neuen Datensatzes
z_tilde <- median(z)          # Median des neuen Datensatzes

cat("Mittelwert und Median für Datensatz mit Ausreißer:", # Ausgabe
    mean(z), median(z))
```

Mittelwert und Median für Datensatz mit Ausreißer: 118.44 19

Definition (Modalwert)

$y := (y_1, \dots, y_n)$ mit $y_i \in \mathbb{R}$ sei ein Datensatz, $W := \{w_1, \dots, w_k\}$ mit $k \leq n$ seien die im Datensatz vorkommenden verschiedenen Zahlenwerte und $h : W \rightarrow \mathbb{N}$ sei die absolute Häufigkeitsverteilung der Zahlwerte von y . Dann ist der *Modalwert (oder Modus)* von y definiert als

$$\operatorname{argmax}_{w \in W} h(w), \quad (13)$$

also als der im Datensatz am häufigsten vorkommende Wert.

Bemerkungen

- Modalwerte sind nur bei Datensätzen mit Datenpunktwiederholungen sinnvoll.

Bestimmung des Modalwertes in R


```
y      <- D$Pre.BDI           # Pre-Interventions-BDI-II-Daten
n      <- length(y)           # Anzahl der Datenwerte (100)
H      <- as.data.frame(table(y)) # absolute Haeufigkeitsverteilung (dataframe)
names(H) <- c("a", "h")       # Konsistente Benennung
mode_a <- H$a[which.max(H$h)] # Modalwert Alt. a
mode_b <- H$a[H$h == max(H$h)] # Modalwert Alt. b (falls mehrerer Maxima)

cat("Modalwert der PRE-BDI-II-Daten über: ", # Ausgabe als numeric vector, nicht factor
    as.numeric(as.vector(mode_a)))
```


Modalwert der PRE-BDI-II-Daten über: 18

Visuelle Intuition zu Maßen zentraler Tendenz bei **Normalverteilung**

Mittelwert = 49.7, Median = 49.0, Modalwert = 48.0




Visuelle Intuition zu Maßen zentraler Tendenz bei **Gleichverteilung**




Visuelle Intuition zu Maßen zentraler Tendenz bei **bimodalen Verteilungen**

Mittelwert = 49.9, Median = 49.5, Modalwert = 21.0



Visuelle Intuition [...] bei **nicht-symmetrischen Verteilungen**

Mittelwert = 1.0, Median = 0.8, Modalwert = 0.2



Maße der zentralen Tendenz

Maße der Datenvariabilität

Definition (Spannbreite)

$y = (y_1, \dots, y_n)$ sei ein Datensatz. Dann ist die *Spannbreite* von $y_1, \dots, y_n$ definiert als

$$r := \max(y_1, \dots, y_n) - \min(y_1, \dots, y_n). \quad (14)$$

Spannbreitenberechnung mit `min()` und `max()`

```
# Spannbreitenberechnung
y      <- D$Pre.BDI                                # Pre-Interventions-BDI-II-Daten
y_max  <- max(y)                                    # Maximum der Werte
y_min  <- min(y)                                    # Minimum der Werte
r      <- y_max - y_min                             # Spannbreite
cat("Spannbreite der Pre.BDI Daten: ", r)          # Ausgabe
```

Spannbreite der Pre.BDI Daten: 9

Spannbreitenberechnung mit `range()`

```
MinMax <- range(y)                                # "automatische" Berechnung von min(y), max(y)
r      <- MinMax[2] - MinMax[1]                    # Spannbreite
cat("Spannbreite der Pre.BDI Daten: ", r)          # Ausgabe
```

Spannbreite der Pre.BDI Daten: 9

Definition (Unkorrigierte empirische Varianz und empirische Varianz)

$y = (y_1, \dots, y_n)$ sei ein Datensatz mit $n > 1$ und $\bar{y}$ sei sein Mittelwert. Dann ist die *unkorrigierte empirische Varianz* von y definiert als

$$\tilde{s}^2 := \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2 \quad (15)$$

und die *empirische Varianz* von y ist definiert als

$$s^2 := \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2. \quad (16)$$

Theorem (Verhältnis von unkorrigierter empirischer Varianz und empirischer Varianz)

$y = (y_1, \dots, y_n)$ sei ein Datensatz und $\tilde{s}^2$ und s^2 seien seine unkorrigierte empirische Varianz und empirische Varianz, respektive. Dann gelten

(1) (Umrechnung)

$$\tilde{s}^2 = \frac{n-1}{n} s^2 \text{ und } s^2 = \frac{n}{n-1} \tilde{s}^2. \quad (17)$$

(2) (Ungleichung)

$$0 \leq \tilde{s}^2 \leq s^2. \quad (18)$$

Verhältnis von unkorrigierter empirischer Varianz und empirischer Varianz

Beweis

(1) Nach der Definition oben gilt zum einen

$$\begin{aligned}\tilde{s}^2 &= \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2 \\ \Leftrightarrow \frac{n-1}{n-1} \tilde{s}^2 &= \frac{n-1}{n-1} \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2 \\ \Leftrightarrow \tilde{s}^2 &= \frac{n-1}{n} \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2 \\ \Leftrightarrow \tilde{s}^2 &= \frac{n-1}{n} s^2\end{aligned}\tag{19}$$

und zum anderen

$$\begin{aligned}s^2 &= \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2 \\ \Leftrightarrow \frac{n}{n} s^2 &= \frac{n}{n} \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2 \\ \Leftrightarrow s^2 &= \frac{n}{n-1} \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2 \\ \Leftrightarrow s^2 &= \frac{n}{n-1} \tilde{s}^2.\end{aligned}\tag{20}$$

Verhältnis von unkorrigierter empirischer Varianz und empirischer Varianz

Beweis (fortgeführt)

(2) Mit der Nichtnegativität der Quadratfunktion sowie $\frac{1}{n} > 0$ und $\frac{1}{n-1} > 0$ für $n > 1$ ergeben sich $\tilde{s}^2 \geq 0$ und $\tilde{s}^2 > 0$ direkt. Schließlich gilt für $\sum_{i=1}^n (y_i - \bar{y})^2 \neq 0$

$$\frac{1}{n} < \frac{1}{n-1} \Leftrightarrow \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2 < \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2 \Leftrightarrow \tilde{s}^2 < s^2. \quad (21)$$

und für $\sum_{i=1}^n (y_i - \bar{y})^2 = 0$ offenbar $\tilde{s}^2 = s^2$. Insgesamt gilt also

$$0 \leq \tilde{s}^2 \leq s^2. \quad (22)$$

Berechnen der Stichprobenvarianz in R

Bestimmung der Stichprobenvarianz anhand der in (15) und (16) festgelegten Formeln

```
y      <- D$Pre.BDI                                # Pre-Interventions-BDI-II-Daten
n      <- length(y)                                # Anzahl der Werte
s2_tilde <- (1/n)*sum((y - mean(y))^2)              # Unkorrigierte empirische Varianz
s2      <- (1/(n-1))*sum((y - mean(y))^2)          # Empirische Varianz

cat("Unkorrigierte empirische Varianz von y:", round(s2_tilde,3), # Ausgabe
    "\nEmpirische Varianz von y          :", round(s2,3))
```

Unkorrigierte empirische Varianz von y: 2.998

Empirische Varianz von y : 3.028

Bestimmung der Stichprobenvarianz mit var()

```
s2      <- var(y)                                # Empirische Varianz
s2_tilde <- ((n-1)/n)*var(y)                    # Unkorrigierte empirische Varianz

cat("Unkorrigierte empirische Varianz von y:", round(s2_tilde,3), # Ausgabe
    "\nEmpirische Varianz von y          :", round(s2,3))
```

Unkorrigierte empirische Varianz von y: 2.998

Empirische Varianz von y : 3.028

Theorem (Stichprobenvarianz bei linear-affinen Transformationen)

$y = (y_1, \dots, y_n)$ sei ein Datensatz mit empirischer Varianz s_y^2 und $z = (ay_1 + b, \dots, ay_n + b)$ sei der mit $a, b \in \mathbb{R}$ linear-affin transformierte Datensatz mit empirischer Varianz s_z^2 . Dann gilt

$$s_z^2 = a^2 s_y^2. \quad (23)$$

Beweis

$$\begin{aligned} s_z^2 &= \frac{1}{n-1} \sum_{i=1}^n (z_i - \bar{z})^2 \\ &= \frac{1}{n-1} \sum_{i=1}^n (ay_i + b - (a\bar{y} + b))^2 \\ &= \frac{1}{n-1} \sum_{i=1}^n (ay_i + b - a\bar{y} - b)^2 \\ &= \frac{1}{n-1} \sum_{i=1}^n (a(y_i - \bar{y}))^2 \\ &= \frac{1}{n-1} \sum_{i=1}^n a^2 (y_i - \bar{y})^2 \\ &= a^2 \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2 \\ &= a^2 s_y^2. \end{aligned} \quad (24)$$

Stichprobenvarianz bei linear-affinen Transformationen

Beispiel: Stichprobenvarianz bei linear-affinen Transformationen

```
y    <- D$Pre.BDI                                # Pre-Interventions-BDI-II-Daten
s2y  <- var(y)                                    # Empirische Varianz von  $y_1, \dots, y_n$ 
a    <- 2                                          # Multiplikationskonstante
b    <- 5                                          # Additionskonstante
z    <- a*y + b                                    #  $z_i = ay_i + b$ 
s2z  <- var(z)                                    # Empirische Varianz von  $z_1, \dots, z_n$ 

cat("Empirische Varianz von z durch direkte Berechnung:", # Ausgabe
    round(s2z,3))
```

Empirische Varianz von z durch direkte Berechnung: 12.113

```
s2z <- a^2*s2y                                    # Empirische Varianz von  $z_1, \dots, z_n$ 

cat("Empirische Varianz von z nach Theorem          :", # Ausgabe
    round(s2z,3))
```

Empirische Varianz von z nach Theorem : 12.113

Theorem (Verschiebungssatz zur unkorrigierten empirischen Varianz)

$y = (y_1, \dots, y_n)$ sei ein Datensatz, $y^2 := (y_1^2, \dots, y_n^2)$ sei sein elementweises Quadrat und $\bar{y}$ und $\overline{y^2}$ seien die respektiven Mittelwerte. Dann gilt

$$\tilde{s}^2 = \overline{y^2} - \bar{y}^2 \quad (25)$$

Beweis

$$\begin{aligned} \tilde{s}^2 &:= \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2 \\ &= \frac{1}{n} \sum_{i=1}^n (y_i^2 - 2y_i\bar{y} + \bar{y}^2) \\ &= \frac{1}{n} \sum_{i=1}^n y_i^2 - 2\bar{y} \frac{1}{n} \sum_{i=1}^n y_i + \frac{1}{n} \sum_{i=1}^n \bar{y}^2 \\ &= \overline{y^2} - 2\bar{y}\bar{y} + \frac{1}{n} n \bar{y}^2 \\ &= \overline{y^2} - 2\bar{y}^2 + \bar{y}^2 \\ &= \overline{y^2} - \bar{y}^2. \end{aligned} \quad (26)$$

Verschiebungssatz zur unkorrigierten empirischen Varianz

Beispiel: Verschiebungssatz zur unkorrigierten empirischen Varianz

```
# Direkte Berechnung der unkorrigierten empirischen Varianz
y      <- D$Pre.BDI                                # Pre-Interventions-BDI-II-Daten
n      <- length(y)                                # Anzahl Datenpunkte
y_bar  <- mean(y)                                   # Stichprobenmittel
s2_tilde <- (1/n)*sum((y - mean(y))^2)              # Unkorrigierte empirische Varianz
cat("Unkorrigierte empirische Varianz nach Definition      :",
    round(s2_tilde,3))                             # Ausgabe
```

Unkorrigierte empirische Varianz nach Definition : 2.998

```
# Berechnung der unkorrigierten empirischen Stichprobenvarianz mit Theorem
s2_tilde <- mean(y^2) - (mean(y))^2                #  $\bar{y^2} - \bar{y}^2$ 
cat("Unkorrigierte empirische Varianz nach Verschiebungssatz:",
    round(s2_tilde,3))                             # Ausgabe
```

Unkorrigierte empirische Varianz nach Verschiebungssatz: 2.998

Das Theorem gilt nicht für die Stichprobenvarianz

```
# Berechnung der empirischen Stichprobenvarianz
s2      <- var(y)                                   #  $s^2 \neq \bar{y^2} - \bar{y}^2$ 
cat("Empirische Varianz:", round(s2,3))             # Ausgabe
```

Empirische Varianz: 3.028

Definition (Empirische Standardabweichung)

$y = (y_1, \dots, y_n)$ sei ein Datensatz. Die *empirische Standardabweichung* von y ist definiert als

$$s := \sqrt{s^2} \quad (27)$$

und die *unkorrigierte empirische Stichprobenstandardabweichung* von y ist definiert als

$$\tilde{s} := \sqrt{\tilde{s}^2}. \quad (28)$$

Bemerkungen

- In Analogie zu den Eigenschaften der empirischen Varianz und ihrer unkorrigierten Version kann auch die unkorrigierte empirische Standardabweichung in die empirische Standardabweichung umgerechnet werden und umgekehrt, es gelten hier

$$\tilde{s} = \sqrt{\frac{n-1}{n}} s \text{ und } s = \sqrt{\frac{n}{n-1}} \tilde{s}. \quad (29)$$

Berechnung der empirischen Standardabweichung in R

Bestimmung der empirischen Standardabweichung anhand der in (27) festgelegten Formel

```
y      <- D$Pre.BDI           # Pre-Interventions-BDI-II-Daten
n      <- length(y)           # Anzahl der Werte
s      <- sqrt((1 / (n - 1)) * sum((y - mean(y))^2)) # Standardabweichung
cat("Empirische Standardabweichung: ", round(s,3))  # Ausgabe
```

Empirische Standardabweichung: 1.74

Bestimmung der empirischen Standardabweichung mit sd()

```
s      <- sd(y)                # Empirische Standardabweichung
cat("Empirische Standardabweichung: ", round(s,3))  # Ausgabe
```

Empirische Standardabweichung: 1.74

Theorem (Empirische Standardabweichung bei linear-affinen Transformationen)

$y = (y_1, \dots, y_n)$ sei ein Datensatz mit empirischer Standardabweichung s_y und $z = (az_1 + b, \dots, az_n + b)$ sei der mit $a, b \in \mathbb{R}$ linear-affin transformierte Datensatz mit empirischer Standardabweichung s_z . Dann gilt

$$s_z = |a|s_y. \quad (30)$$

Beweis

$$\begin{aligned} s_z &:= \left(\frac{1}{n-1} \sum_{i=1}^n (z_i - \bar{z})^2 \right)^{1/2} \\ &= \left(\frac{1}{n-1} \sum_{i=1}^n (ay_i + b - (a\bar{y} + b))^2 \right)^{1/2} \\ &= \left(\frac{1}{n-1} \sum_{i=1}^n (a(y_i - \bar{y}))^2 \right)^{1/2} \\ &= \left(\frac{1}{n-1} \sum_{i=1}^n a^2 (y_i - \bar{y})^2 \right)^{1/2} \\ &= (a^2)^{1/2} \left(\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2 \right)^{1/2}. \end{aligned} \quad (31)$$

Also gilt $s_z = as_y$, wenn $a \geq 0$ und $s_z = -as_y$, wenn $a < 0$. Dies aber entspricht $s_z = |a|s_y$.

Empirische Standardabweichung bei linear-affinen Transformationen

Empirische Standardabweichung bei linear-affinen Transformationen

```
# a >= 0
y  <- D$Pre.BDI                                # Pre-Interventions-BDI-II-Daten
a  <- 2                                          # Multiplikationskonstante
b  <- 5                                          # Additionskonstante
z  <- a*y + b                                  #  $z_i = ay_i + b$ 
sz <- sd(z)                                    # Empirische Standardabweichung von z
cat("Empirische Standardabweichung von z durch direkte Berechnung:", # Ausgabe
    round(sz,3))
```

Empirische Standardabweichung von z durch direkte Berechnung: 3.48

```
sz <- a*sd(y)                                # Empirische Standardabweichung von z
cat("Empirische Standardabweichung von z nach Theorem          :", # Ausgabe
    round(sz,3))
```

Empirische Standardabweichung von z nach Theorem : 3.48

```
# a < 0
a  <- -3                                       # Multiplikationskonstante
b  <- 10                                      # Additionskonstante
z  <- a*y + b                                  #  $z_i = ay_i + b$ 
sz <- sd(z)                                    # Empirische Standardabweichung von z
cat("Empirische Standardabweichung von z durch direkte Berechnung:", # Ausgabe
    round(sz,3))
```

Empirische Standardabweichung von z durch direkte Berechnung: 5.221

```
sz <- -a*sd(y)                                # Empirische Standardabweichung von z
cat("Empirische Standardabweichung von z nach Theorem          :", # Ausgabe
    round(sz,3))
```

Empirische Standardabweichung von z nach Theorem : 5.221